Học phần: Kho dữ liệu và Kỹ thuật khai phá dữ liệu

1. Tên đề tài

Xây dựng kho dữ liệu khí tượng đa nguồn phục vụ phân tích xu hướng và dự báo khả năng mưa tại miền Bắc Việt Nam

2. Lý do lựa chọn đề tài

Dữ liệu khí tượng là một trong những loại dữ liệu có khối lượng lớn, được thu thập liên tục theo thời gian và được cung cấp từ nhiều nguồn khác nhau như hệ thống quan trắc, API thời tiết, dữ liệu tái phân tích khí tượng và dữ liệu địa lý.

Các nguồn dữ liệu này thường không đồng nhất về:

- cấu trúc dữ liệu;
- định dạng lưu trữ;
- đơn vị đo;
- độ phân giải thời gian;
- tọa độ địa lý;
- cách đặt tên thuộc tính;
- phương pháp thu thập.

Do đó, dữ liệu khí tượng phù hợp để xây dựng một bài toán tổng hợp bao gồm **tích hợp dữ liệu, xây dựng kho dữ liệu, phân tích OLAP và khai phá dữ liệu**.

3. Mục tiêu của đề tài

3.1. Mục tiêu tổng quát

Xây dựng một nền tảng dữ liệu khí tượng có khả năng:

thu thập → lưu trữ → làm sạch → tích hợp → xây dựng kho dữ liệu → phân tích OLAP → khai phá dữ liệu → dự báo khả năng mưa.

Kết quả cuối cùng cung cấp một hệ thống giúp người sử dụng phân tích dữ liệu khí tượng lịch sử và khai thác thông tin hỗ trợ dự báo.

3.2. Mục tiêu cụ thể

Đề tài hướng tới các mục tiêu:

1. Thu thập dữ liệu khí tượng từ nhiều nguồn và nhiều định dạng khác nhau.
2. Xây dựng Data Lake lưu trữ dữ liệu thô và dữ liệu đã chuẩn hóa.
3. Xây dựng quy trình ETL tự động để xử lý và tích hợp dữ liệu.
4. Thiết kế Data Warehouse theo mô hình đa chiều.

5. Xây dựng dashboard BI hỗ trợ phân tích dữ liệu theo thời gian và địa điểm.
6. Áp dụng thuật toán cây quyết định CART để phân loại khả năng xuất hiện mưa trong 24 giờ tiếp theo.
7. Đánh giá mô hình bằng các chỉ số Accuracy, Precision, Recall và F1-score.
8. Ghi kết quả dự báo trở lại kho dữ liệu để kết quả Machine Learning có thể được hiển thị trực tiếp trên dashboard.

4. Phạm vi nghiên cứu

Đề tài tập trung vào một số địa điểm đại diện tại khu vực miền Bắc Việt Nam.

Phạm vi ban đầu dự kiến khoảng **6–10 địa điểm**, chẳng hạn:

- Hà Nội;
- Phú Thọ;
- Thái Nguyên;
- Tuyên Quang;
- Lào Cai;
- Hòa Bình;
- Hải Phòng;
- Ninh Bình.

Khoảng thời gian nghiên cứu dự kiến: **10 năm dữ liệu lịch sử, với mức chi tiết theo giờ.**

5. Nguồn dữ liệu dự kiến

Đề tài không sử dụng duy nhất các file CSV mà cố gắng thể hiện bài toán **tích hợp dữ liệu đa nguồn và đa cấu trúc**.

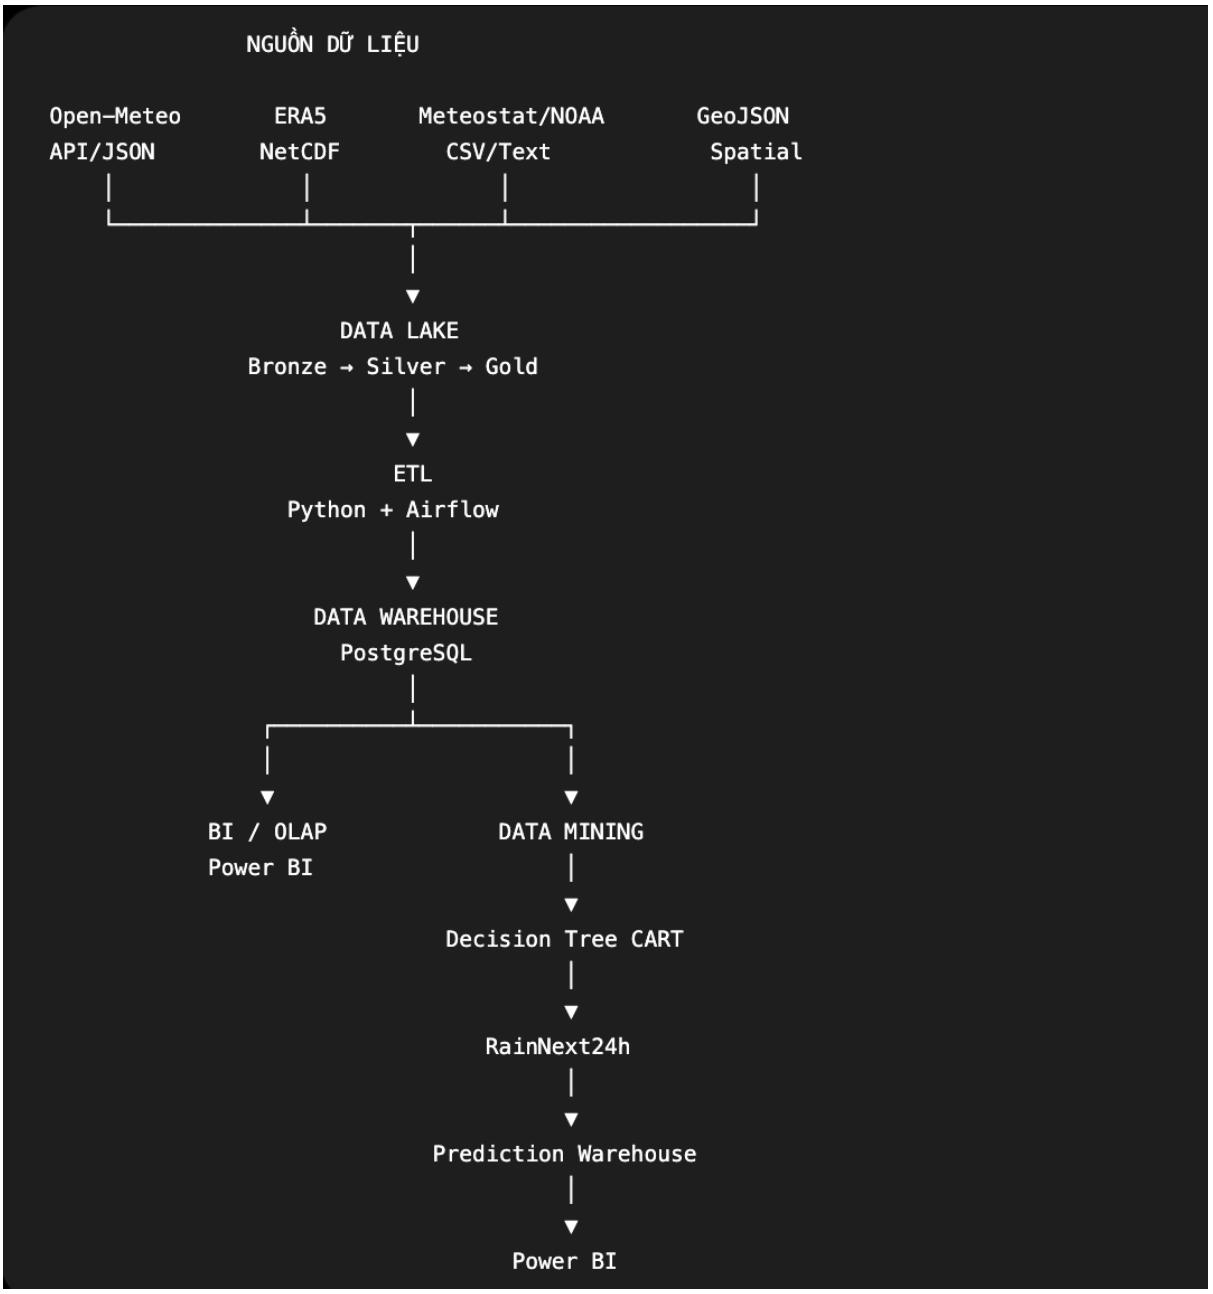
Nguồn	Hình thức	Định dạng	Vai trò
Open-Meteo	REST API	JSON	Dữ liệu khí tượng theo giờ
ERA5 / ERA5-Land	Bulk dataset	NetCDF	Dữ liệu khí tượng lịch sử quy mô lớn
Meteostat hoặc NOAA	Station dataset	CSV/Text	Dữ liệu quan trắc theo trạm

Dữ liệu địa giới Việt Nam	File không gian	GeoJSON	Ánh xạ vị trí và trực quan hóa bản đồ

Các nguồn có thể cung cấp những thuộc tính như:

- nhiệt độ;
- độ ẩm;
- áp suất khí quyển;
- lượng mưa;
- tốc độ gió;
- hướng gió;
- độ che phủ mây;
- bức xạ mặt trời;
- tọa độ địa lý;
- thông tin trạm.

6. Kiến trúc tổng thể của hệ thống



Điểm chính của kiến trúc là các thành phần **không hoạt động độc lập** mà tạo thành một pipeline dữ liệu hoàn chỉnh.

7. Thiết kế Data Lake

Data Lake sử dụng **MinIO**, gồm 3 tầng:

- **Bronze:** lưu dữ liệu nguyên bản từ các nguồn.
- **Silver:** làm sạch, loại bỏ trùng lặp, xử lý missing value, chuẩn hóa thuộc tính, timestamp, timezone, đơn vị đo và tọa độ.
- **Gold:** lưu dữ liệu đã xử lý, phục vụ Data Warehouse, BI và Machine Learning.

8. Quy trình ETL

Sử dụng **Python và Apache Airflow** để xây dựng pipeline ETL. Dữ liệu từ nhiều nguồn thời tiết được thu thập, làm sạch, chuẩn hóa và tích hợp về một cấu trúc thống nhất trước khi đưa vào Data Warehouse.

9. Thiết kế Data Warehouse

Sử dụng **PostgreSQL** với mô hình **Star Schema**.

- **Fact:** `FactWeatherObservation`
- **Dimension:** `DimDate`, `DimTime`, `DimLocation`, `DimSource`, `DimStation`.

Grain của Fact là **một nguồn dữ liệu × một vị trí × một thời điểm theo giờ**.

10. Phân tích BI và OLAP

Sử dụng **Power BI** để xây dựng dashboard phân tích:

- nhiệt độ và lượng mưa theo thời gian;
- so sánh giữa các khu vực và nguồn dữ liệu;
- số ngày mưa, ngày nhiệt độ cao;
- xu hướng thời tiết;
- bản đồ dữ liệu khí tượng.

Hỗ trợ các thao tác OLAP: **Roll-up, Drill-down, Slice và Dice**.

11. Khai phá dữ liệu

Xây dựng bài toán **phân loại khả năng xuất hiện mưa trong 24 giờ tiếp theo** với hai lớp:

- `RainNext24h = Yes`
- `RainNext24h = No`

Thuật toán sử dụng: **Decision Tree (CART)**.

Các đặc trưng gồm nhiệt độ, độ ẩm, áp suất, lượng mưa, mây, gió và các biến biến đổi theo thời gian.

12. Đánh giá mô hình

Dữ liệu được chia theo **thời gian**:

- **2016–2023:** Training
- **2024:** Validation
- **2025:** Testing

Đánh giá bằng **Confusion Matrix, Accuracy, Precision, Recall và F1-score**, trong đó chú trọng Recall để phát hiện các trường hợp có mưa.

13. Tích hợp Machine Learning

Kết quả dự báo được lưu trở lại Data Warehouse trong bảng **FactWeatherPrediction**, bao gồm thời điểm dự báo, khả năng mưa, xác suất mưa và phiên bản mô hình.

14. Công nghệ dự kiến

Thành phần	Công nghệ
Data Lake	MinIO
Orchestration	Apache Airflow
ETL	Python
Tabular processing	Pandas
NetCDF processing	Xarray
Spatial processing	GeoPandas
Data Warehouse	PostgreSQL
Machine Learning	Scikit-learn
BI/OLAP	Power BI
Runtime	Docker / Docker Compose

Đề tài không đặt mục tiêu sử dụng các công nghệ Big Data phức tạp như Hadoop, Spark hoặc Kubernetes nếu quy mô dữ liệu chưa yêu cầu.

15. Kết quả dự kiến

Sau khi hoàn thành, đề tài dự kiến có các sản phẩm:

1. **Data Lake** chứa dữ liệu khí tượng đa nguồn.
2. Pipeline **ETL tự động**.
3. Bộ dữ liệu khí tượng đã được chuẩn hóa và tích hợp.
4. **Data Warehouse theo mô hình Star Schema**.
5. Dashboard **Power BI/OLAP**.
6. Mô hình **Decision Tree CART** dự báo khả năng mưa.
7. Kết quả đánh giá mô hình bằng Confusion Matrix và các chỉ số phân loại.
8. Bảng lưu trữ kết quả Prediction trong Warehouse.
9. Dashboard kết hợp dữ liệu lịch sử và kết quả dự báo.

16. Tính khả thi và điểm nổi bật

Đề tài có một số ưu điểm:

Thứ nhất, nguồn dữ liệu phong phú. Dữ liệu khí tượng có lịch sử dài và có thể thu thập từ nhiều nguồn công khai.

Thứ hai, thể hiện rõ nội dung của môn học. Đề tài không chỉ tập trung vào Machine Learning mà kết hợp:

> **Data Integration + Data Lake + ETL + Data Warehouse + OLAP + Data Mining.**

Thứ ba, dữ liệu có tính đa dạng về cấu trúc. Hệ thống xử lý JSON, CSV/Text, NetCDF và GeoJSON.

Thứ tư, kết quả có khả năng trực quan hóa tốt. Dữ liệu thời gian và không gian phù hợp với biểu đồ xu hướng và bản đồ.

Thứ năm, thuật toán ML dễ giải thích. Decision Tree cho phép biểu diễn trực quan các luật phân loại và phù hợp với nội dung của giáo trình.

Cuối cùng, phạm vi có thể điều chỉnh. Nhóm có thể bắt đầu với một số địa điểm và nguồn dữ liệu giới hạn rồi mở rộng nếu thời gian cho phép.